

データ構造と操作

第2講 - R言語で扱うデータとその演算

村田 昇

講義概要

- R言語のデータ構造
- ベクトル・行列・リストの操作
- ベクトルと行列のさまざまな計算

R言語のデータ構造

基本的なデータ構造

- 下記は基本的なもので標準環境で利用できる
 - ベクトル (vector)
 - 行列 (matrix)
 - リスト (list)
 - データフレーム (data frame)
 - 配列 (array) (今回は扱わない)
- **パッケージ**で拡張することができる
 - **データフレームの拡張** (tibble, data.table など)
 - **時系列の扱い** (zoo, xts など)

ベクトル

ベクトルとは

- 同じデータ型の値 (スカラー値) の集合
 - 数値 (実数や複素数)
 - 文字列 (' や “ で囲まれた文字, ”foo“, ”bar” など)
 - 論理値 (TRUE, FALSE)
- R オブジェクトの多くはベクトルとして扱われる
- スカラーは長さ 1 のベクトルとして扱われる

ベクトルの生成

- 数値や文字列の要素からなるベクトルの生成

```
(x <- c("Alice", "Bob", "Cathy", "David"))      # 文字列のベクトル
(y <- c(1, -2, 3, -4, 5))                        # 数値のベクトル
```

```
(z <- c("apple", "berry", "cat", "dog", "elephant")) # 文字列のベクトル
#' 外側の ( ) は代入した結果の表示. print() と同義
```

```
[1] "Alice" "Bob"    "Cathy" "David"
[1] 1 -2 3 -4 5
[1] "apple"    "berry"    "cat"      "dog"      "elephant"
```

- a から b まで 1 ずつ変化するベクトル (演算子 :)

```
a <- 8; b <- 15 # 変数 a, b に値を代入. 複数コマンドは ; で区切る
a:b            # a < b の場合は 1 ずつ増加する系列が作成される
a <- 29.5; b <- 24
a:b            # 逆の場合は 1 ずつ減少する系列が作成される
29.5:24        # 直接数値を書いてもよい
```

```
[1] 8 9 10 11 12 13 14 15
[1] 29.5 28.5 27.5 26.5 25.5 24.5
[1] 29.5 28.5 27.5 26.5 25.5 24.5
```

- a から b まで c ずつ変化するベクトル (関数 seq())

```
a <- 1; b <- 16; c <- 2 # 変数 a, b, c に値を代入
seq(a, b, by = c)       # 明示する場合は seq(from = a, to = b, by = c)
```

```
[1] 1 3 5 7 9 11 13 15
```

ベクトルの操作

- ベクトルの長さの取得 (関数 length())

```
length(x) # 最後の要素を参照する場合などに利用できる
```

```
[1] 4
```

- ベクトルの要素の取得 (演算子 [])

```
x[3]          # x の第 3 要素 (ベクトルの添え字は 1 から始まる)
y[c(1,3,4)]   # 複数の要素 = c(y[1], y[3], y[4])
```

```
[1] "Cathy"
[1] 1 3 -4
```

- ベクトルの反転 (関数 rev())

```
rev(x)
```

```
[1] "David" "Cathy" "Bob"    "Alice"
```

- ベクトルの結合 (関数 c())

```
c(x, z) # 同じデータ型のものは単純に結合される
c(x, y) # 異なるデータ型のものは結合できないので自動的に書き換えられる
```

```
[1] "Alice"    "Bob"      "Cathy"    "David"    "apple"    "berry"
[7] "cat"      "dog"      "elephant"
[1] "Alice" "Bob"    "Cathy" "David" "1"      "-2"     "3"      "-4"      "5"
```

- ベクトルの繰り返し (関数 rep())

```
rep(y, 3)           # 長さは length(y) * 3
rep(y, times = 3)   # 単純に繰り返す。上記と同様
rep(y, each = 3)    # 各要素を繰り返す
rep(y, length.out = 12) # 繰り返した結果の長さを指定する
```

```
[1] 1 -2 3 -4 5 1 -2 3 -4 5 1 -2 3 -4 5
[1] 1 -2 3 -4 5 1 -2 3 -4 5 1 -2 3 -4 5
[1] 1 1 1 -2 -2 -2 3 3 3 -4 -4 -4 5 5 5
[1] 1 -2 3 -4 5 1 -2 3 -4 5 1 -2
```

実習

行列

行列とは

- スカラー値を2次元状(縦横)に並べたもの
 - 縦(列)ベクトルを列方向に並べて束ねたもの
 - 横(行)ベクトルを行方向に並べて束ねたもの
- データ型は何でもよいが **混在はできない**
- データフレームは行列を拡張したもの

行列の生成

- すべての要素が a である $m \times n$ 型行列の生成
(関数 `matrix()`)

```
a <- 2; m <- 3; n <- 4 # 変数 a, m, n に値を代入
matrix(a, m, n)        # 明示する場合は matrix(data = a, nrow = m, ncol = n)
```

```
      [,1] [,2] [,3] [,4]
[1,]    2    2    2    2
[2,]    2    2    2    2
[3,]    2    2    2    2
```

- 長さ mn のベクトル a を $m \times n$ 型行列に変換
(関数 `matrix()`)

```
a <- 2:13 # 変数 a に値を代入 (m*n = 12 文字用意)
(A <- matrix(a, m, n)) # 並び順を変えるには matrix(a, m, n, byrow = TRUE)
```

```
      [,1] [,2] [,3] [,4]
[1,]    2    5    8   11
[2,]    3    6    9   12
[3,]    4    7   10   13
```

- 行列のベクトル化 (関数 `as.vector()`)

```
as.vector(A) # matrix の逆変換にあたる
```

```
[1] 2 3 4 5 6 7 8 9 10 11 12 13
```

- 長さが等しい複数のベクトルの結合
(関数 `rbind()`, `cbind()`)

```
a <- 4:7; b <- 10:7; c <- c(2,4,8,16) # 変数 a,b,c に値を代入
rbind(a, b, c) # 行ベクトルとして結合 (row vector bind)
cbind(a, b, c) # 列ベクトルとして結合 (column vector bind)
```

```
      [,1] [,2] [,3] [,4]
a         4     5     6     7
b        10     9     8     7
c         2     4     8    16

      a b c
[1,] 4 10 2
[2,] 5  9 4
[3,] 6  8 8
[4,] 7  7 16
```

行列の操作

- 行列のサイズの取得 (関数 `dim()` とその仲間)

```
dim(A)      # 関数の返値は長さ 2 のベクトル (行数, 列数) となることに注意
nrow(A)     # 行数
ncol(A)     # 列数
dim(A)[1]   # nrow(A) と同値
dim(A)[2]   # ncol(A) と同値
```

```
[1] 3 4
[1] 3
[1] 4
[1] 3
[1] 4
```

- 行列の成分の取得 (演算子 `[]`)

```
A[3,4]      # (3,4) 成分
A[3, ]      # 第 3 行のベクトル
A[ ,4]      # 第 4 列のベクトル
A[c(1,3),]  # 1,3 行からなる部分行列. 2x4 型行列になる
A[c(1,3),2:4] # 1,3 行と, 2,3,4 列からなる部分行列. 2x3 型行列になる
```

```
[1] 13
[1]  4  7 10 13
[1] 11 12 13

      [,1] [,2] [,3] [,4]
[1,]     2     5     8    11
[2,]     4     7    10    13

      [,1] [,2] [,3]
[1,]     5     8    11
[2,]     7    10    13
```

行列の操作に関する補足

- 関数 `cbind()/rbind()` は行数・列数が等しい行列も横・縦に結合できる
- 行列の高次元版として配列 (array) が用意されている
- 関数 `rownames()/colnames()` を用いると行と列に名前を付けることができる
- これらの機能は講義の中で使いながら説明する

実習

その他のデータ構造

リストとは

- 異なる構造のオブジェクトを1つにまとめたもの
 - リストの各要素は異なるデータ型・サイズであって構わない
 - 複数のデータフレームを扱うときなどに応用可能
- 本講義のデータ解析ではほとんど用いない
 - Rの関数の操作ではときどき必要
- データフレームはリストの特殊なもの

リストの生成と操作

- リストの生成 (関数 `list()`)

```
(L <- list(x,y)) # x,y を要素とするリスト
```

```
[[1]]  
[1] "Alice" "Bob"   "Cathy" "David"
```

```
[[2]]  
[1] 1 -2 3 -4 5
```

- リストの要素の参照 (演算子 `[]`)

```
L[[1]] # リストの第1要素
```

```
[1] "Alice" "Bob"   "Cathy" "David"
```

- リストの各要素に名前を付与 (関数 `names()`)

```
#' 方法1 (作成時に名前を付与)  
(L1 <- list(first=x, second=y))
```

```
$first  
[1] "Alice" "Bob"   "Cathy" "David"
```

```
$second  
[1] 1 -2 3 -4 5
```

```
#' 方法2 (作成後に名前を変更)  
L2 <- list(x,y)  
names(L2) <- c("1st", "2nd")  
L2 # リストを表示
```

```
$`1st`  
[1] "Alice" "Bob"   "Cathy" "David"
```

```
$`2nd`  
[1] 1 -2 3 -4 5
```

- 名前によるリストの要素の取得 (演算子 `[]`, `$`)

```
#' 方法 1 (リストの名前で参照)
L1[["first"]]
L2[["2nd"]]
```

```
[1] "Alice" "Bob"  "Cathy" "David"
[1] 1 -2 3 -4 5
```

```
#' 方法 2 (記号$を用いる場合は""は不要なことに注意)
L1$first
L2$`2nd` # 数字で始まる文字列は ``を用いる必要がある
```

```
[1] "Alice" "Bob"  "Cathy" "David"
[1] 1 -2 3 -4 5
```

データフレームとは

- 長さの等しいベクトルを束ねたリスト
- 複数の属性を持つ実データに則したデータ構造
- 各列は異なるデータ型でも良い
- データフレームは **リスト** でもある
リストと同様にして各変数を取得できる
- データフレームは **行列** のように扱える
行列と同様にして各変数を取得できる

データフレームの生成

- データフレームの生成 (関数 `tibble()`)

```
#' 前回の練習問題
library(tibble)
(foo <-
  tibble(
    name = c("Alice", "Bob", "Carol", "Dave", "Eve"),
    math = c(90, 80, 70, 60, 50),
    phys = c(25, 50, 75, 100, 80),
    chem = c(65, 100, 70, 40, 75),
    bio = c(70, 50, 30, 80, 100)))
```

- 操作については別の回に詳細に説明する

ベクトルの計算

ベクトルの表記

- ベクトルは太字、要素は下付き添字で表す

$$\mathbf{a} = (a_1, a_2, \dots, a_k)$$

- 別の書き方

$$(\mathbf{a})_i = (\text{ベクトル } \mathbf{a} \text{ の第 } i \text{ 成分})$$

- R の書式 (関数 `c()`)

```
a <- c(a1,a2,...,ak) # k次元ベクトルの作成 (擬似コード)
```

ベクトルの加法

- 同じ長さのベクトルの和および差

$$\mathbf{a} \pm \mathbf{b} = (a_1 \pm b_1, a_2 \pm b_2, \dots, a_k \pm b_k)$$

$$(\mathbf{a} \pm \mathbf{b})_i = a_i \pm b_i$$

- 数値の和と差のように扱うことができる

- R の書式 (演算子 +, -)

```
a + b # 同じ長さのベクトル a, b の和, 同じ長さのベクトルが返る  
a - b # ベクトルの差
```

ベクトルの乗法

- 同じ長さの2つのベクトルの乗法
 - 成分ごとの積 (Hadamard 積; 要素積)
 - ベクトルの内積

2種類あることに注意する

- データ解析ではどちらも良く用いられる

Hadamard 積

- 同じ長さのベクトルの成分ごとの積

$$\mathbf{a} \circ \mathbf{b} = (a_1 b_1, a_2 b_2, \dots, a_k b_k)$$

$$(\mathbf{a} \circ \mathbf{b})_i = a_i b_i$$

- R の書式 (演算子 *, /)

```
a * b # ベクトルの成分ごとの積, 同じ長さのベクトルが返る  
a / b # 成分ごとの商も計算可
```

内積

- 同じ長さのベクトルの内積

$$\mathbf{a} \cdot \mathbf{b} = a_1 b_1 + a_2 b_2 + \dots + a_k b_k$$

$$= \sum_{i=1}^k a_i b_i$$

- R の書式 (演算子 %*%)

```
a %*% b # ベクトルの内積, 1x1型の行列が返る
```

行列の計算

行列の表記

- 行列は大文字, 要素は下付き添字で表す

$$A = \begin{pmatrix} a_{11} & \dots & a_{1n} \\ \vdots & \ddots & \vdots \\ a_{m1} & \dots & a_{mn} \end{pmatrix}$$

- 別の書き方

$$(A)_{ij} = (\text{行列 } A \text{ の } ij \text{ 成分})$$

- R の書式 (関数 `matrix()`)

```
A <- matrix(c(a11,a21,...,amn), m, n) # m x n 型行列の作成 (擬似コード)
```

行列の加法

- 同じ大きさの行列 の和および差

$$(A \pm B)_{ij} = a_{ij} \pm b_{ij}$$

- ベクトルと同じように記述することができる

- R の書式

```
A + B # 同じサイズの行列の和, 同じサイズの行列が返る  
A - B # 行列の差
```

行列の乗法

- 2つの行列の乗法
 - 同じ大きさの行列 の成分ごとの積 (Hadamard 積; 要素積)
 - $n \times m$ 型行列と $m \times l$ 型行列 の積

2種類あることに注意する

- データ解析ではどちらも良く用いられる

Hadamard 積

- 同じ大きさの行列 の成分ごとの積

$$(A \circ B)_{ij} = a_{ij} b_{ij}$$

- R の書式 (演算子 `*`, `/`)

```
A * B # 行列の成分ごとの積, 同じサイズの行列が返る  
A / B # 成分ごとの商も計算可
```

行列の積

- $n \times m$ 型行列 A と $m \times l$ 型行列 B の積

$$(AB)_{ij} = \sum_{k=1}^m a_{ik} b_{kj} \quad (AB \text{ は } n \times l \text{ 行列})$$

- R の書式 (演算子 `%%`)

```
A %% B # 行列の積, n x l 型行列が返る
```

行列式

- n 次正方行列 A の行列式

$$\det(A) \quad (= |A|)$$

- 正方行列でなければ定義されない ことに注意する

- R の書式 (関数 `det()`)

```
det(A) # 行列式
```

トレース

- n 次正方行列 A のトレース (対角成分の総和)

$$\text{trace}(A) = \sum_{i=1}^n a_{ii}$$

- R の書式 (関数を用意されていないので以下を利用)

```
sum(diag(A)) # 行列のトレース
```

- 関数 `diag()`: 行列の対角成分を取り出す
(引数がベクトルの場合はそれを対角成分とする対角行列を返す)
- 関数 `sum()`: ベクトルの総和を計算する

実習

例題

- 適当な 2 次正方行列 A で Hamilton-Cayley の定理

$$A^2 - \text{trace}(A)A + \det(A)E_2 = O_2$$

の成立を確認せよ. ただし E_2 は 2 次単位行列, O_2 は 2 次正方零行列とする.

- 解答例

```
#' 行列を作成 (好きに設定してよい)
(A <- matrix(1:4,2,2) - diag(rep(3,2)))
#' 左辺を計算 (丸め誤差の範囲で 0 になる)
A %% A - sum(diag(A)) * A + det(A) * diag(rep(1,2))
```

```

      [,1] [,2]
[1,]   -2   3
[2,]    2   1
      [,1]      [,2]
[1,] 1.776357e-15 0.000000e+00
[2,] 0.000000e+00 1.776357e-15

```

ベクトルと行列の計算

ベクトルと行列の乗法

- 演算子 `%*%` を用いて計算する
 - 列 (縦) ベクトル・行 (横) ベクトルという **区別はない**
 - 行列とベクトルの順序で適切に判断される
 - 演算子 `%*%` による計算結果は **行列** で表現される

```

A <- matrix(1:4, 2, 2); b <- c(5,6) # 行列とベクトルを作成
A %*% b                               # 行列 x ベクトル = 列ベクトル

```

```

      [,1]
[1,]   23
[2,]   34

```

```

b %*% A                               # ベクトル x 行列 = 行ベクトル

```

```

      [,1] [,2]
[1,]   17   39

```

連立 1 次方程式の解法

- 連立 1 次方程式
 - A : n 次正則行列
 - b, x : n 次元列ベクトル

$$Ax = b \quad (\text{連立 1 次方程式})$$

$$x = A^{-1}b \quad (A \text{ が正則な場合})$$

- 解を求めるには関数 `solve()` を利用する

```

x <- solve(A, b)

```

- ベクトル b の代わりに行列も扱える

逆行列

- 正則な n 次正方行列 A の逆行列 A^{-1}

$$AA^{-1} = A^{-1}A = E_n \quad (E_n \text{ は } n \text{ 次単位行列})$$

- 関数 `solve()` を利用して求めることができる

$$AX = E_n, \quad X = A^{-1}E_n = A^{-1}$$

```
solve(A,B) #  $AX=B$  の解  $X$  を求める  
solve(A)   # 逆行列 ( $B$  が単位行列の場合省略できる)
```

– 他にもいくつか方法は用意されている

関数の適用

- ベクトルや行列に関数 ($\sin, \exp, \dots$ など) を適用すると成分ごとに計算した結果が返される
- ベクトル $\mathbf{a}$, 行列 A に関数 $\sin$ を適用する

$$(\sin(\mathbf{a}))_i = \sin(a_i)$$

$$(\sin(A))_{ij} = \sin(a_{ij})$$

```
sin(a) # 成分ごとに計算される.  $\sin(a)[i]=\sin(a[i])$   
sin(A) # 成分ごとに計算される.  $\sin(A)[i,j]=\sin(A[i,j])$ 
```

実習

例題

- 適当な 3 次正方行列 A と 3 次元ベクトル $\mathbf{b}$ を作成して $\mathbf{x}$ に関する以下の連立 1 次方程式を解きなさい

$$A\mathbf{x} = \mathbf{b}$$

- 解答例

```
(A <- matrix(rnorm(9), 3, 3) + diag(rep(1, 3))) # 行列とベクトルを作成  
# 'rnorm(9)' は正規乱数を 9 つ作成する (後の講義で詳しく説明)  
(b <- 1:3)
```

```
      [,1]      [,2]      [,3]  
[1,] 0.8437664 -1.244162 1.196313448  
[2,] -0.1363162 1.465178 0.005984311  
[3,] -0.8397992 1.221587 0.735853994  
[1] 1 2 3
```

```
(x <- solve(A, b)) # 解を計算  
A %*% x           # 結果の確認 (b になるはず)
```

```
[1] 0.2643207 1.3810942 2.0858079  
      [,1]  
[1,]    1  
[2,]    2  
[3,]    3
```

次回の予定

- R 言語における関数
- 引数の扱い方 (引数名・順序・既定値)
- 自作関数の定義
- 制御構造 (条件分岐・繰り返し)