データの可視化

第5講-様々なグラフの描画

村田昇

講義の内容

- 可視化の重要性
- 基本的な描画
- 分布の視覚化
- 比率の視覚化
- 多次元データの視覚化

可視化の重要性

可視化のための機能

- データの特徴や傾向を把握するために効果的
- R はきわめて多彩な作図機能を持つ
- package::graphics に含まれる代表的な描画関数を取り上げて解説する
 - 描画関連の関数は色、線の種類や太さ、あるいは図中の文字の大きさなどを指定することができる
 - 用意されている多彩なオプションは説明しきれないため、必要に応じて関数 help()(ヘルプ)と 関数 example()(例題)を参照のこと

図の保存

- RStudio の機能を使う場合:
 - 1. 右下ペインの "Plots" タブの "Export" をクリック
 - 2. 形式を指定する

クリップボードにコピーもできる

- 3. サイズを指定して保存
- コンソール / R Script で実行する場合:
 - help("pdf"): PDF ファイルに保存
 - help("png"): PNG ファイルに保存
 - help("dev.copy"): "graphic device" 間でコピー

などを参照

サンプルデータの説明

- jpdata[1-3].csv(再掲)
 - https://www.e-stat.go.jp(統計局)
 - * 地域から探す/全県を選択/項目を選択してダウンロード
 - * 日本語が扱えることを想定して日本語
 - * 英語のために -en を用意
 - データファイル (文字コード: utf8)
 - * jpdata1.csv: 県別の対象データ
 - * jpdata2.csv:対象データの内容説明
 - * jpdata3.csv: 県と地域の対応関係
 - 作業ディレクトリの data 内に置いて読み込む場合

```
JP.data <- read.csv(file="data/jpdata1.csv", fileEncoding="utf8", row.names=1)
JP.item <- read.csv(file="data/jpdata2.csv", fileEncoding="utf8")
JP.area <- read.csv(file="data/jpdata3.csv", fileEncoding="utf8")</pre>
```

- * 変数名は自由に付けてよい
- tokyo_weather.csv(tokyo.zipの中)
 - https://www.jma.go.jp(気象庁)
 - * 各種データ・資料 / 過去の地点気象データ・ダウンロード
 - * 地点/項目/期間を選択してダウンロード
 - データ項目

平均気温 (°C), 降水量の合計 (mm), 合計全天日射量 (MJ/m³), 降雪量合計 (cm), 最多風向 (16 方位), 平均風速 (m/s), 平均現地気圧 (hPa), 平均湿度 (%), 平均雲量 (10 分比), 天気概況 (昼:06 時~18 時), 天気概況 (夜:18 時~翌日 06 時)

- 作業ディレクトリの data 内に置いて読み込む場合

```
TW.data <- read.csv(file="data/tokyo_weather.csv")</pre>
```

- tokyo_covid19_2021.csv(tokyo.zipの中)
 - https://stopcovid19.metro.tokyo.lg.jp(東京都)
 - データ項目

陽性者数,総検査実施件数,発熱等相談件数

- 作業ディレクトリの data 内に置いて読み込む場合

TC.data <- read.csv(file="data/tokyo_covid19_2021.csv", fileEncoding="utf8")

基本的な描画

関数 plot()

• ベクトルデータの描画を行う関数

関数 plot() のオプション

• よく利用される ... の部分

- col: 色の指定. "red" や "blue" など. 指定可能な色は関数 colors() を参照

- pch: 点の形. 詳細は help("points") を参照

- lty:線のタイプ. 実線・破線など. タイプ名もしくは数字で指定. 詳細は help("par")を参照

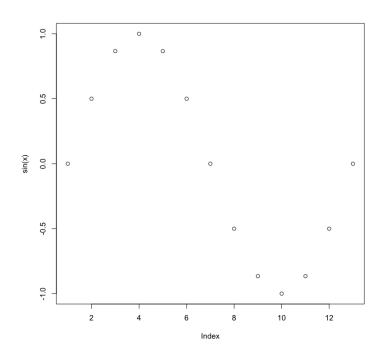
- 1wd: 線の太さ. 数字で指定

- cex: 文字の大きさ. 既定値の何倍にするかを指定

ベクトルの描画の例

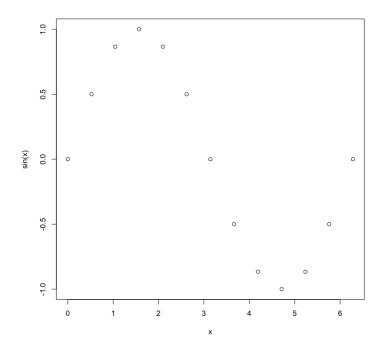
- 1 変数の場合 plot(x)
- 2 変数の場合 plot(x,y)
- 基本的なオプションの指定例
- 1 変数の場合 plot(x)

 $x \leftarrow pi/6*(0:12)$ # 30度 (pi/6) おきに 1 周期分 (0-2*pi) plot(sin(x)) # x 軸はベクトルの要素番号 (Index), y 軸は sin(x) の値を描画



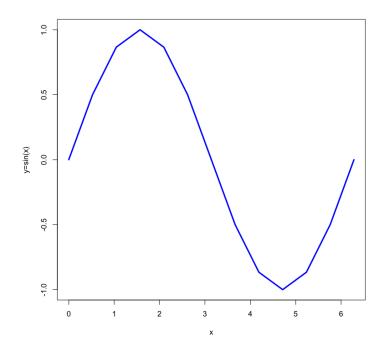
• 2 変数の場合 plot(x,y)

x <- pi/6*(0:12) plot(x, sin(x)) # x の値に対する y=sin(x) の値を対応づけて描画



• オプションの例

x <- pi/6*(0:12)
plot(x,sin(x),type="1",lwd=3,col="blue",ylab="y=sin(x)")</pre>



重ね描きのための関数

• 別のベクトルを点として重ね描きする場合

```
points(x, y = NULL, ...) # ... は関数 plot() と同様なオプションが指定可能
```

• 別のベクトルを線として重ね描きする場合

```
lines(x, y = NULL, ...) # ... は関数 plot() と同様なオプションが指定可能
```

• 文字を重ね描きする場合

```
text(x, y = NULL, labels, ...) # labelsに文字列を指定
```

重ね描きの例

• ベクトルデータの重ね描き

```
x <- seq(0, 4*pi, by=0.5)
y <- sin(x)
z <- cos(x)
plot(x, y, type="b", pch="x", ylim=c(-2,2), col="red") # "b"="p+l"
points(x, z, col="blue", pch="C") # 点を追加. pch は文字も指定できる
lines(x, z, col="cyan", lwd=3) # 折れ線を追加
```

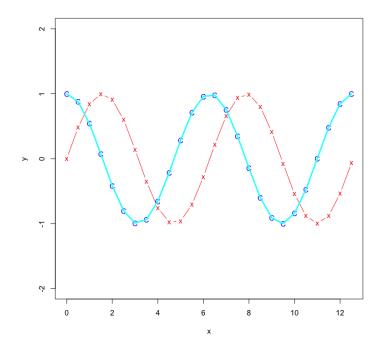


図 1: ベクトルデータの重ね描き

関数 curve()

• 1 変数関数の描画を行う関数

```
curve(expr, from = NULL, to = NULL, add = FALSE,type = "1", xname = "x", xlab = xname, ylab = NULL, ...)## expr: 1変数関数 (関数名)## from: x 軸の左端## to: x 軸の右端
```

```
## add: TRUE で重ね描きする
## xname: x 軸の変数名
```

• 関数 plot() にも同様の機能がある

```
plot(x, y = 0, to = 1, ...) # ... は"ベクトルの描画"と同様に指定が可能
```

関数の描画の例

• 関数の描画

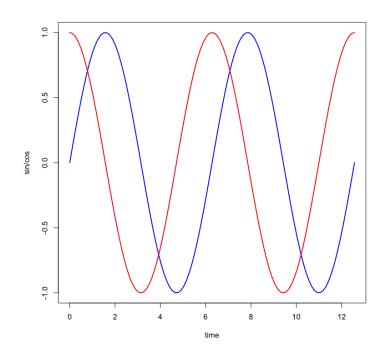


図 2: 関数の描画

• 関数とベクトルデータの重ね描き

```
x <- seq(0, 4*pi, by=0.25)
y <- sin(x) + rep(c(-0.2, 0.1), len=length(x))
plot(x, y, type="p", pch="x", ylim=c(-2,2), col="red")
lines(x, y, col="blue", lwd=2) # 折れ線を追加
curve(sin, add=TRUE, col="orange", lwd=3)
```

散布図

- 2種類のデータ x_1, \ldots, x_n および y_1, \ldots, y_n が与えられたとき、同じ index を持つ点 $(x_1, y_1), \ldots, (x_n, y_n)$ を平面上に描画した図
- データの性質を捉えるための基本的な描画の方法

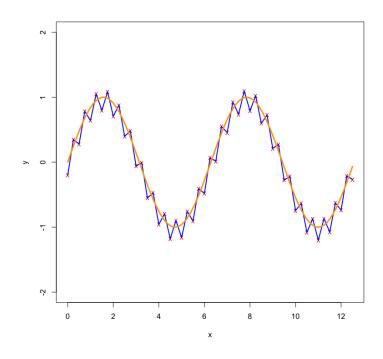


図 3: 関数とベクトルデータの重ね描き

関数 plot()

• ベクトルデータの散布図を作成する(既出の機能)

```
plot(x, y = NULL, ...) #... は"ベクトルの描画"と同様に指定が可能 ## x: 1 種類目のデータ c(x1,x2,...) ## y: 2 種類目のデータ c(y1,y2,...) (x と同じ長さ)
```

関数 plot()

• データフレーム x の変数 A, B の散布図を作成する

```
plot(B ~ A, data = x, ...) # "Y軸 ~ X軸" と指定
## x: データフレーム
## A,B: 変数名 (データフレームの列名を利用可能)
## "B ~ A" は formula と呼ばれる
```

- formula の書き方は help("formula") を参照
- データフレーム x に対して plot(x) を実行すると、すべての変数のペアに対する散布図が作成される (散布図行列・対散布図; pairs() 後述)

散布図の例

• データフレームを用いた散布図

```
plot(Ozone ~ Wind, data=airquality, # xy 軸名は列の名前が使われる
    pch="*", # 点の形を文字で指定することもできる
    col="red",
    cex=2) # cex は点の大きさの倍率を指定する
```

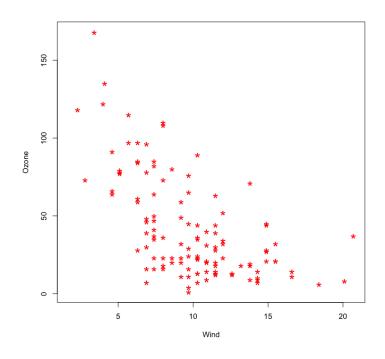


図 4: データフレームを用いた散布図

日本語に関する注意

- ・日本語を含む図で文字化けが起こった場合 (主に macOS)
 - 関数 par の family オプションでフォントを指定 ヒラギノ角ゴシック W4 を指定する場合

par(family="HiraginoSans-W4") # 数字を変えると太さが変わる

- 以下のサイトなども参考になる https://oku.edu.mie-u.ac.jp/~okumura/stat/font.html

演習

練習問題

- jpdata1/3.csv (前回配布のデータ) を用いて以下の問に答えよ.
 - 婚姻・離婚率の散布図を描け.
 - 地方別に異なる点の形状を用いた散布図を描け、
 - それ以外にも様々な散布図を描画してみよう.
 - (参考) 読み込み方

```
## CSVファイルは作業ディレクトリの下の data サブディレクトリにあるとする
JP.data <- read.csv(file="data/jpdata1.csv", fileEncoding="utf8", row.names=1)
JP.area <- read.csv(file="data/jpdata3.csv", fileEncoding="utf8")
```

分布の視覚化

ヒストグラム

• データの値の範囲をいくつかの区間に分割し、各区間に含まれるデータ数を棒グラフにしたもの

- 各棒グラフの矩形
 - 横幅が区間に対応
 - 面積が区間に含まれるデータの個数に比例
- データの分布の仕方を可視化するのに有効
 - どのあたりに値が集中しているか
 - どの程度値にばらつきがあるか

関数 hist()

• ヒストグラムを描画する関数

```
hist(x, breaks = "Sturges", freq, ...) # ... は関数 plot() と同様に指定可能
## x: ベクトル
## breaks: 区間の分割の仕方を指定. 既定値は Sturges の公式.
## 数字を指定するとデータ範囲をその数字に近い個数に等分割する.
## 詳細はヘルプを参照
## freq: TRUE (既定値) を指定すると縦軸はデータ数
## FALSE を指定すると縦軸はデータ数/全データ数
```

ヒストグラムの例

• 関数 hist() によるヒストグラムの作図

```
if(Sys.info()["sysname"]=="Darwin"){par(family="HiraginoSans-W4")} # 日本語表示 ## 東京都の気温のヒストグラムを作成する
TW.data <- read.csv("data/tokyo_weather.csv") # 東京都の気象データの読み込み hist(TW.data$temp, xlab="気温(°C)", ylab="頻度", breaks=25, # ビンの数を約 25 に設定 labels=TRUE, # 各ビンの度数を表示 col="lightpink", main="気温のヒストグラム")
```

• 密度での表示

```
if(Sys.info()["sysname"]=="Darwin"){par(family="HiraginoSans-W4")} # 日本語表示
hist(TW.data$wind, freq=FALSE, # 全体に対する割合で表示
xlab="風速 (m/s)", ylab="密度",
breaks=25,
col="lightblue", border="blue", # 長方形の境界の色
main="風速の密度")
```

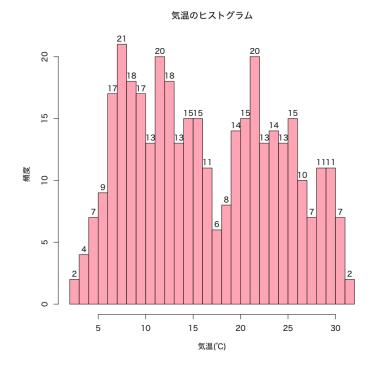
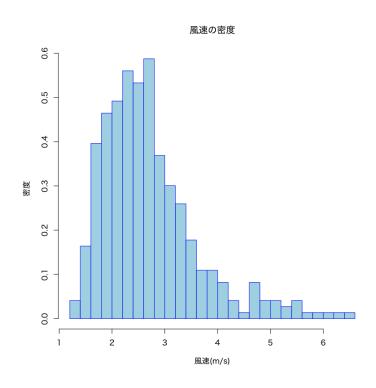


図 5: ヒストグラム



箱ひげ図

- データの中心、散らばり具合および外れ値を考察するための図 (ヒストグラムの簡易版)
- 複数のデータの分布の比較の際に有効
 - 太線で表示された中央値 (第2四分位点)
 - 第1四分位点を下端・第3四分位点を上端とする長方形(箱)

- 第1四分位点・第3四分位点からそれぞれ箱の長さの1.5倍以内にあるデータのうちの最小の値・ 最大の値を下端・上端とする直線(ひげ)
- ひげの外側のデータは点で表示される

関数 boxplot()

• 箱ひげ図を描画する関数

```
      boxplot(x, ...) # ... は関数 plot() と同様に指定可能

      ## x: ベクトルまたはデータフレーム

      ## ベクトルに対しては単一の箱ひげ図

      ## データフレーム対しては列ごとの箱ひげ図
```

• 質的変数ごとに分類して描画する場合

```
boxplot(B ~ A, data = x, ...)
## x: データフレーム
## A: x の変数 (質的変数; 性別・植物の種類など)
## B: x の変数
```

箱ひげ図の例

• 関数 boxplot() による箱ひげ図の作図

```
if(Sys.info()["sysname"]=="Darwin"){par(family="HiraginoSans-W4")} # 日本語表示
## 気温, 降雨,日射,降雪,風速の箱ひげ図を作成する
boxplot(subset(TW.data, select=c(temp:snow,wind)), # 数値データの一部を抽出
names=c("気温","降雨","日射","降雪","風速")) # 各箱ひげ図の名前を指定
## names を指定しなければ列名が使われる
```

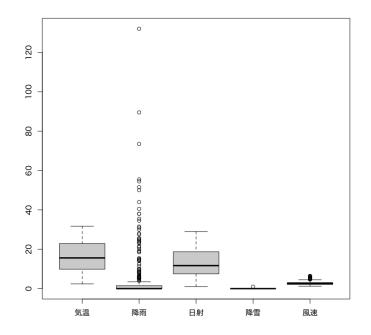


図 6: 箱ひげ図

• 箱を横向きにする場合

```
if(Sys.info()["sysname"]=="Darwin"){par(family="HiraginoSans-W4")} # 日本語表示 ## 気温, 降雨,日射,降雪,風速の箱ひげ図を作成する boxplot(subset(TW.data, select=c(temp:snow,wind)), # 数値データの一部を抽出 names=c("気温","降雨","日射","降雪","風速"), # 各箱ひげ図の名前を指定 horizontal=TRUE) # 図を横向きに回転する
```

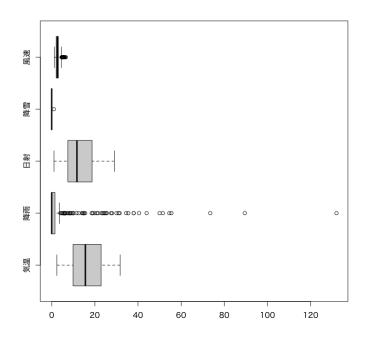


図 7: 箱ひげ図 (横向き)

• 条件ごとの箱ひげ図の作図

比率の視覚化

関数 barplot()

• 棒グラフを作成する関数

```
barplot(x, width = 1, space = NULL, beside = FALSE, legend.text = NULL, args.legend = NULL, ...) # ... は関数 plot() と同様に指定可能 ## x: ベクトルまたは行列 (データフレームは不可) ## width: 棒の幅 ## space: 棒グラフ間・変数間のスペース ## legend.text: 凡例 ## beside: 複数の変数を縦に並べるか・横に並べるか
```

月ごとの気温

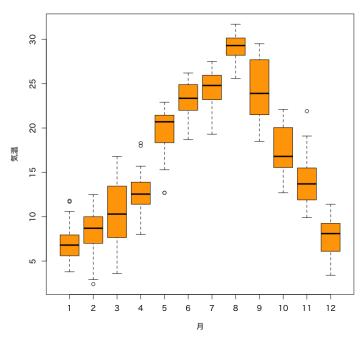


図 8: 条件ごとの箱ひげ図

args.legend: 関数 legend() に渡す引数

棒グラフの例

• 関数 barplot() による棒グラフの作図

• 複数の棒グラフ

```
if(Sys.info()["sysname"]=="Darwin"){par(family="HiraginoSans-W4")} # 日本語表示 ## 気温,降雨,日射,降雪,風速の月ごとの棒グラフを作成する barplot(as.matrix(foo[,-1]),#第1引数のデータフレームは行列にする col=rainbow(12)[c(8:1,12:9)],#12色に色分け.季節に合うように色を並べ変えている beside=TRUE,#各列ごとの棒グラフを横に並べる space=c(1.5,3),#棒グラフ間・変数間のスペースを指定 names.arg=c("気温","降雨","日射","降雪","風速"),#各列の名前を指定.指定しなければ列名が使われる legend.text=pasteO(foo$month,"月"),#凡例の指定 args.legend=list(ncol=2))#凡例を2列にして表示
```

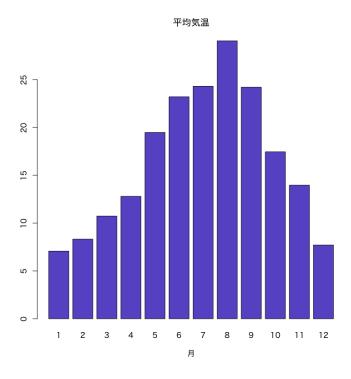
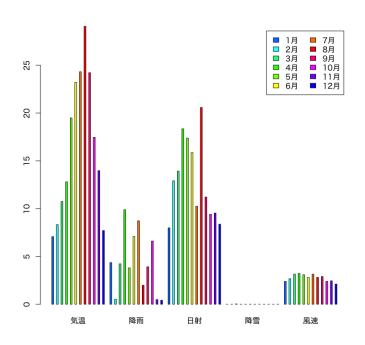


図 9: 棒グラフ



関数 pie()

• 円グラフを作成する関数

```
pie(x, labels = names(x),
clockwise = FALSE, ...) # ... は関数 plot() と同様に指定可能
## x: ベクトル
```

labels: ベクトルの各成分のラベル (既定値ではベクトルから取得) ## clockwise: 時計回りに書くか否か

円グラフの例

• 関数 pie() による円グラフの作図

```
if(Sys.info()["sysname"]=="Darwin") {par(family="HiraginoSans-W4")} # 日本語表示 ## ヒストグラムの機能を用いてデータの集計を行う foo <- hist(TW.data$solar, breaks=5, plot=FALSE) # 5つ程度に分類を指定。実際には6つに分類 bar <- foo$count # 各ビン内のデータ数 baz <- foo$breaks # ビンの境界 names(bar) <- paste(baz[-length(baz)],baz[-1],sep="-") # ビンの範囲の文字列を作成 ## 6つに分類した日射量ごとの日数の割合を示す円グラフを作成する pie(bar, clockwise=TRUE, main="日射量別の日数の割合", col=heat.colors(length(bar),rev=TRUE)) # 日射量が高いほど赤を濃く指定
```

日射量別の日数の割合

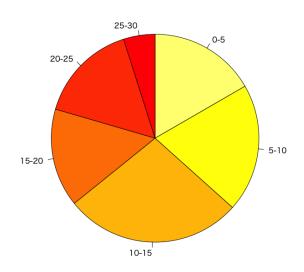


図 10: 円グラフ

演習

練習問題

- tokyo covid19 2021.csv (東京都の新型コロナの動向データ) を用いて以下の問に答えよ.
 - 陽性者数の推移の折線グラフを描け.
 - 総検査実施件数の推移の棒グラフを描け.
 - 曜日ごとの総検査実施件数の箱ひげ図を描け.
 - (参考) 読み込み方

多次元データの視覚化

関数 pairs()

• 散布図行列 (対散布図) を作成する関数

```
pairs(x, ...) # 関数 plot() でも良い
## x: データフレーム
```

- すべての列のペアに対する散布図を行列状に配置
- 変数 A1,..., Ak (列名) のみ考える場合

```
pairs(~ A1 + ... + Ak, data = x, ...) # 関数 plot() でも良い
## x: データフレーム
## A1,...,Ak: データフレームの列名
```

散布図行列の例

• 関数 pairs() による散布図の作図

```
if(Sys.info()["sysname"]=="Darwin"){par(family="HiraginoSans-W4")} # 日本語表示 ## 気温,日射,風速に関する散布図を作成する pairs(~ temp + solar + wind, data=TW.data, labels=c("気温","日射","風速"), # 指定しなければ列名が使われる col=rainbow(12)[TW.data*month]) # 月毎に異なる色で表示
```

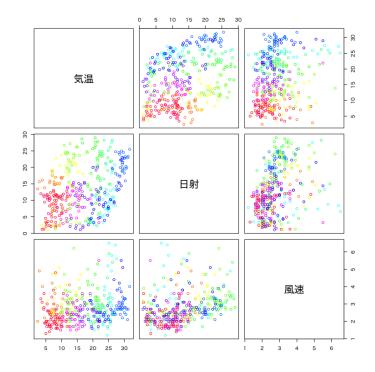


図 11: 散布図行列

関数 persp()

・ 3 次元のグラフを 2 次元に射影した俯瞰図を描く関数

```
persp(x, y, z, theta = 0, phi = 15, expand = 1, ...) # ... は関数 plot() と同様に指定可能 ## x,y,z: x,y,z 座標 ## z は点 (x[i],y[j]) に対応する値を (i,j) 成分とする行列で与える必要がある ## theta,phi: 俯瞰の方向を指定する極座標 #expand: z軸の拡大度
```

3次元俯瞰図の例

• 関数 persp() による 2 変数関数の俯瞰図

```
f <- function(x,y) x^2 - y^2
x <- seq(-3, 3, length=51) # x 座標の定義域の分割
y <- seq(-3, 3, length=51) # y 座標の定義域の分割
z <- outer(x, y, f) # z 座標の計算
# 基本的な俯瞰図
## persp(x, y, z, col="lightblue")
## 俯瞰する向きを指定
persp(x, y, z, theta=30, phi=30, expand=0.5, # 俯瞰する視線の設定
col="royalblue", main=expression(z==x^2-y^2))
```

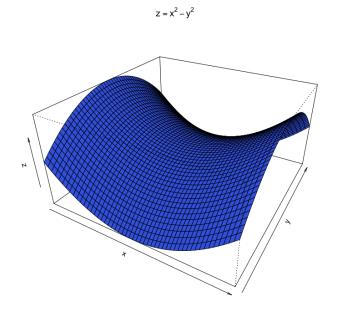


図 12: 俯瞰図

3次元グラフのためのパッケージ

• 以下は scatterplot3d() の例

```
library(scatterplot3d) # パッケージの読み込み
scatterplot3d(x, color, angle = 40, ...) # ... は関数 plot() とは若干異なる
## x: x,y,z座標を指定するデータフレーム
## 関数 persp() のように x,y,z を個別に指定することも可能
```

```
## color: 色を指定 (col\ \ \ \ \ \ \ \ \ \ \ \ \ \ \ \ \ \ ). 既定値は黒 ## angle:\ x 軸と y 軸の間の角度
```

- 詳細は example("scatterplot3d")を参照

3次元散布図の例

• 関数 scatterplot3d() による 3 次元散布図

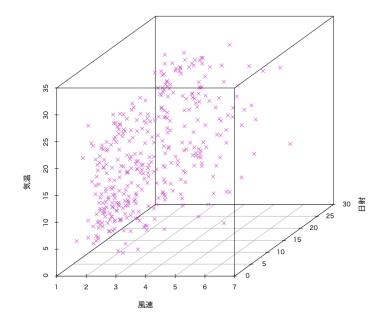


図 13:3 次元散布図

凡例の追加

関数 legend()

• グラフに凡例を追加する関数

```
legend(x, y = NULL, legend, ...) # ... はその他のオプション
## x,y: 凡例の位置を指定 (座標やキーワードで指定が可能)
## legend: 凡例の文字列ベクトル
```

- 複雑なオプションは help("legend") を参照
- 数式の表示の詳細は help("plotmath") を参照

凡例の例

• 凡例の追加

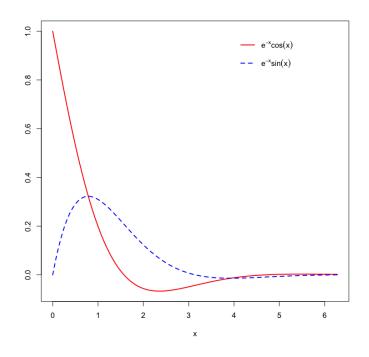
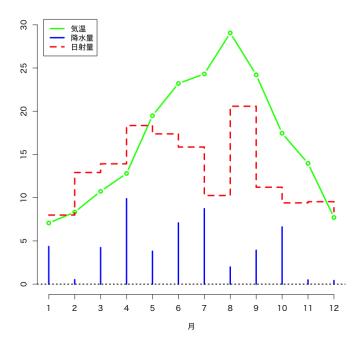


図 14: 凡例の追加

• 東京の気象データを用いた例

```
if(Sys.info()["sysname"]=="Darwin"){par(family="HiraginoSans-W4")} # 日本語表示 ## 東京の気象データから月ごとの気温,降水量,日射量の平均を計算し描画する (foo <- aggregate(.~ month, FUN=mean, data=subset(TW.data, select=c(month,temp,rain,solar)))) plot(foo$temp, type ="b", lwd=3, col="green", ylim=c(0, max(foo$temp)+1), xlab="月", ylab="", main="東京の気候データ", axes=FALSE) # 軸は無 axis(1, 1:12, 1:12); axis(2) # x(1),y(2) 軸の作成 lines(foo$rain, type="h", lwd=3, col="blue") # 棒グラフ lines(foo$solar, type="s", lwd=3, lty=2, col="red") # 階段グラフ abline(0, 0, lwd=2, lty="dotted") # y=0の線を引く legend("topleft", inset=0.02, # 左上で全体の 2%(0.02) 内側に良せる legend=c("気温","降水量","日射量"), col=c("green","blue","red"), lwd=3, lty=c(1,1,2))
```





補遺

関数 par()

• グラフィクス環境の設定 (複数図の配置, 余白の設定) をする関数

par(tag = value)
tag: グラフィックスパラメータ

- 描画の際の線の種類や色,点の形等の既定値を設定することができる
- 設定可能なグラフィックスパラメータは help("par") を参照

package::ggplot2

- R のグラフィック機能を拡張するパッケージの1つ
- 統一的な文法で系統的に美しいグラフを描くことを目指して開発
- 詳細については https://docs.ggplot2.org/ を参照

演習

練習問題

- 配布したサンプルデータ
 - jpdata1.csv
 - tokyo_weather.csv
 - covid19_tokyo.csv
 - covid19_tokyo_patients.csv

を用いて以下の問いに答えよ.

- 3次元の散布図を作成せよ.
- 凡例を加えたグラフを作成せよ.

次回の予定

- 計算機による数値実験
- 乱数とは
- 乱数を用いた数値実験