

確率シミュレーション

第6講 - 乱数を用いた数値実験

村田 昇

講義の内容

- 計算機による数値実験
- 乱数とは
- 乱数を用いた数値実験

計算機による数値実験

データ解析の枠組

- 分析の目的
 - 集団の背後にある共通の法則の発見
 - 推測された法則に基づく将来の予測
- 集団全体のデータが入手できることは稀
 - 現時点の集団に含まれているとは限らない
 - 将来のデータは入手不可
- 分析における課題

分析対象の集団の一部のデータのみを用いて、そこから集団全体の性質についての知見を得るには？

データのもつべき性質

- 偏った一部のデータから全体の性質の推測は困難
 - 知りたい事柄：日本全体の平均気温
 - 得られるデータ：沖縄県の各地点の気温
- 直感的にはデータを **ランダム** に収集すれば良い
 - そもそもランダムとは？
 - ランダムにデータを収集するコストは？
- データ収集の問題

ランダムにデータを収集することで分析における課題が解決できる根拠は？

理論解析と数値実験

- データ収集の問題
 - ランダムにデータを収集することで分析における課題が解決できる根拠は？
- 厳密な意味での解答
 - (測度論的) 確率論
 - その理解のための他の数学分野
- 乱数を使った数値実験
 - 計算機上でランダムネスを実現
 - ランダムネスから結論される数学的結果を直接観察

乱数とは

擬似乱数

- コンピューターで生成された数列
 - 完全にランダムに数字を発生させることは不可能
 - R では **Mersenne-Twister 法** が標準で用いられる
 - `help(Random)` 参照
- 数値シミュレーションは再現可能
 - 乱数の **シード値** を指定して再現性を担保
 - 同一のシード値から生成される乱数系列は同一
 - 関数 `set.seed()` 参照

基本的な乱数

- **ランダムサンプリング** (無作為抽出)
 - 与えられた集合の要素をランダムに抽出する乱数
- **二項乱数**
 - 確率 p で表が出るコインを n 回投げた際の表の数
 - 確率 p に対する次数 n の二項乱数
- **一様乱数**
 - 決まった区間 (a, b) からランダムに発生する乱数
 - 区間 (a, b) 上の一様乱数
- **これ以外にも種々の乱数が存在**

乱数を発生する関数

- R には様々な確率分布に従う乱数が実装されている
 - `base::sample()` : ランダムサンプリング
 - `stats::rbinom()` : 二項乱数
 - `stats::runif()` : 一様乱数
- これ以外は次回以降で取り上げる

関数の利用例

- 関数 `sample()` の使い方

```
#' 関数 sample() の使い方
x <- 1:10 # サンプルング対象の集合をベクトルとして定義
set.seed(123) # 乱数のシード値(任意に決めてよい)を指定
sample(x, 5) # xから5つの要素を重複なしでランダムに抽出
sample(x, length(x)) # xの要素のランダムな並べ替えとなる
sample(x, 5, replace=TRUE) # xから5つの要素を重複ありでランダムに抽出
sample(1:6, 10, replace=TRUE) # サイコロを10回振る実験の再現
sample(1:6, 10, prob=6:1, replace=TRUE) # 出る目の確率に偏りがある場合
```

```
[1] 3 10 2 8 6
[1] 5 4 6 8 1 2 3 7 9 10
[1] 9 9 9 3 8
[1] 2 2 1 6 3 4 6 1 3 5
[1] 1 1 2 2 2 1 1 1 2 1
```

- 関数 rbinom()/runif() の使い方

```
#' 関数 rbinom() の使い方
rbinom(10, size=4, prob=0.5) # 確率0.5に対する次数4の二項乱数を10個発生
rbinom(20, size=4, prob=0.2) # 個数を20, 確率を0.2に変更
#' 関数 runif() の使い方
runif(5, min=-1, max=2) # 区間(-1,2)上の一様乱数を5個発生
runif(5) # 指定しない場合は区間(0,1)が既定値
```

```
[1] 3 0 2 3 1 2 1 1 3 3
[1] 0 1 0 0 0 1 1 1 1 1 1 1 1 0 1 0 0 1 0
[1] -0.6665937 -0.2691416 1.0041668 0.2529403 1.3645875
[1] 0.1028646 0.4348927 0.9849570 0.8930511 0.8864691
```

- 関数 set.seed() について

```
#' 関数 set.seed() の使い方
set.seed(1) # 乱数のシード値をseed=1で指定
runif(5)
set.seed(2) # 乱数のシード値をseed=2で指定
runif(5) # seed=1の場合と異なる系列が観測される
set.seed(1) # 乱数のシード値をseed=1で指定
runif(5) # 初めのseed=1の場合と同じ系列が再現される
```

```
[1] 0.2655087 0.3721239 0.5728534 0.9082078 0.2016819
[1] 0.1848823 0.7023740 0.5733263 0.1680519 0.9438393
[1] 0.2655087 0.3721239 0.5728534 0.9082078 0.2016819
```

乱数を用いた数値実験

確率シミュレーション

- 確率的現象の理解
 - 抽象化・単純化した問題: 詳細な理論的解析が可能
 - 複雑な問題: 理論的に解析を行うことが難しい
- 計算機上の擬似乱数を利用した数値的解析
 - 確率シミュレーション (stochastic simulation)
 - モンテカルロ法 (Monte-Carlo method)
 などと呼ばれる
- 利点
 - 計算機上では繰り返しシミュレーションが可能
 - 原因となる要素を自由に設定して結果の観察が可能

繰り返し実験の関数

- 同じ手続きを指定した回数繰り返して評価
- 関数 `base::replicate()` :

```
replicate(n, expr, simplify = "array")
#' n: 繰り返し回数
#' expr: 評価する手続き (関数を定義) (1回の実験に相当)
#' simplify: 出力の形式を指定
```

数値実験の例

- 2つのサイコロを振る試行

```
#' 2つのサイコロを振る試行の数値実験
#' 試行 (1回の実験)を行う関数を用意する
my_trial <- function(){ # この問題では引数は不要
  dice <- sample(1:6, 2, replace=TRUE) # 2個のサイコロを振る
  return(dice)
}
#' 乱数のシード値を指定
set.seed(20240524)
#' 確率シミュレーションを実行
my_data <- replicate(10, # 10回実験
                     my_trial()) # 実行する関数を指定
print(my_data) # 実験結果は行列 (配列)として保存されている
```

	[,1]	[,2]	[,3]	[,4]	[,5]	[,6]	[,7]	[,8]	[,9]	[,10]
[1,]	3	2	6	5	5	1	3	4	2	4
[2,]	6	2	4	6	6	5	6	1	6	5

演習

確率シミュレーションの例

Buffon の針

- 問題

2次元平面上に等間隔 d で平行線が引いてある。長さ l の針をこの平面上にランダムに落としたとき、平行線と交わる確率はいくつか？ ただし $l \leq d$ とする。

 - 針の位置 (例えば中心) と平行線となす角度が適当な範囲でランダムに選ばれると考えればよい

Monty Hall 問題

- 問題

ゲームの参加者の前に閉まった3つのドアがあって、1つのドアの後ろには景品の新車が、2つのドアの後ろには外れを意味するヤギがいる。参加者は新車が置かれたドアを当てると新車がもらえる。

参加者が1つのドアを選択した後、司会のモンティが残りのドアのうちヤギがいるドアを開けてヤギを見せる。ここで参加者は、最初に選んだドアを残っているドアに変更してもよいと言われる。

参加者はドアを変更すべきだろうか？

秘書問題 (最適停止問題)

- 問題

以下の条件のもと秘書を 1 人雇うとする.

- n 人が応募しており n は既知とする.
- 応募者には 1 位から n 位まで順位付けできる.
- 無作為な順序で 1 人ずつ面接を行う.
- 毎回の面接後その応募者を採用するか否かを決定する.
- 不採用にした応募者を後から採用することはできない.

“ $r - 1$ 番までの応募者は採用せず, r 番以降の応募者でそれまで面接した中で最も良い者を採用する” という戦略を取るとき, 最適な r はいくつだろうか?

次回の予定

- 独立な確率変数の性質
- 大数の法則
- 中心極限定理
- 少数の法則