

極限定理

第7講 - 大数の法則・中心極限定理・少数の法則

村田 昇

講義概要

- 独立な確率変数の性質
- 大数の法則
- 中心極限定理
- 少数の法則

基本事項の確認

確率変数

- 乱数の数学モデル：値がランダムに決定される変数
- 任意の区間 $[a, b]$ に含まれる確率が定められている
 - 数学的には厳密性を欠くが、本講義ではこの定義
- 確率変数 X が区間 $[a, b]$ ($a \leq b$) に含まれる確率

$$P(a \leq X \leq b)$$

- 特に $a = b$ のとき $P(X = a)$ と書く
- 今回は有限個の値のみをとる確率変数を考える
 - 無限個の値、特に連続的な値については次回以降

平均と分散

- 確率変数 X の観測値： $x_1, x_2, \dots, x_N$
- 平均 もしくは 期待値

$$\mathbb{E}[X] = \sum_{i=1}^N x_i P(X = x_i)$$

- 分散 (= 標準偏差²)

$$\text{Var}(X) = \mathbb{E}[(X - \mathbb{E}[X])^2] = \mathbb{E}[X^2] - \mathbb{E}[X]^2$$

例題

- 偏ったサイコロの問題

確率変数 X は偶数の目の出る確率が奇数の目の出る確率の 2 倍であるサイコロの目を表すとする。

$$P(X = 1) = P(X = 3) = P(X = 5) = 1/9$$

$$P(X = 2) = P(X = 4) = P(X = 6) = 2/9$$

このとき X の平均と分散を求めよ。

- 解答 (計算例)

X の平均は

$$\mathbb{E}[X] = \sum_{x=1}^6 xP(X=x) = 11/3 = 3.6666\dots$$

X の分散は

$$\mathbb{E}[X^2] = \sum_{x=1}^6 x^2P(X=x) = 49/3$$

$$\text{Var}(X) = 49/3 - 121/9 = 26/9 = 2.88\dots$$

- 解答 (R を用いた計算例)

```
#' 平均と分散の計算
p <- rep(c(1/9,2/9),3) # 確率の値 (1/9 と 2/9 を交互に3回繰り返す)
x <- 1:6 # サイコロの目の値
(mu <- sum(x*p)) # 平均値の計算
(v <- sum((x-mu)^2*p)) # 分散の計算
sqrt(v) # 標準偏差
```

```
[1] 3.666667
```

```
[1] 2.888889
```

```
[1] 1.699673
```

```
#' 正規化しないで計算する方法もある
w <- rep(1:2,3) # 1,2 の繰り返し (確率ではない)
weighted.mean(x,w)
weighted.mean(x^2,w)-weighted.mean(x,w)^2
```

```
[1] 3.666667
```

```
[1] 2.888889
```

独立性と同分布性

同時分布

- 観測データは確率変数の集合
- 確率変数列 $X_1, X_2, \dots, X_n$ に対する考察が重要
- 定義

“ X_1 が x_1 という値をとり, X_2 が x_2 という値をとり, ..., X_n が x_n という値をとる” という事象が起きる確率を**同時分布**という.

$$P(X_1 = x_1, X_2 = x_2, \dots, X_n = x_n)$$

独立性

- 無関係にサンプリングされた観測データの性質
- 定義

確率変数列 $X_1, X_2, \dots, X_n$ が**独立**であるとは, 任意の n 個の実数 $x_1, x_2, \dots, x_n$ に対して

$$P(X_1 = x_1, X_2 = x_2, \dots, X_n = x_n) = P(X_1 = x_1) \cdot P(X_2 = x_2) \cdots P(X_n = x_n)$$

が成り立つことをいう.

同分布性

- 同一の法則に従って生成された観測データの性質
- 定義

確率変数列 $X_1, X_2, \dots, X_n$ が**同分布**であるとは, 任意の実数 x に対して

$$P(X_1 = x) = P(X_2 = x) = \cdots = P(X_n = x)$$

が成り立つことをいう.

独立同分布性

- 一般に分析対象のデータには**独立性**と**同分布性**が同時に仮定される
- 定義

独立かつ同分布である確率変数列を**独立同分布**もしくは**i.i.d.**であるという.

– i.i.d. は independent and identically distributed の略

無限列の独立性と同分布性

- 無限列に対しては任意の部分列について考える
- 独立性

$X_1, X_2, \dots$ が**独立**であるとは, 任意の正整数 n に対して $X_1, X_2, \dots, X_n$ が独立であることをいう.

- 同分布性

$X_1, X_2, \dots$ が**同分布**であるとは, 任意の正整数 n に対して $X_1, X_2, \dots, X_n$ が同分布であることをいう.

- 独立同分布性

$X_1, X_2, \dots$ が **独立同分布** もしくは **i.i.d.** であるとは, $X_1, X_2, \dots$ が独立かつ同分布であることをいう.

大数の法則

大数の法則の概要

- 要点

同一の法則に従って生成された集団から **ランダム** な観測を多数繰り返すと, **観測値の平均** は **真の平均値** に近づく

- 例
 - 歪みの無いコインの表が出た回数の割合
 - 視聴率の調査
- この法則を数学的に定式化した定理が **大数の法則**

大数の強法則

- 定理

$X_1, X_2, \dots$ を独立同分布な確率変数列とし, その平均を μ とする. このとき, $X_1, \dots, X_n$ の標本平均

$$\bar{X}_n = \frac{1}{n} \sum_{i=1}^n X_i$$

が $n \rightarrow \infty$ のとき μ に収束する確率は 1 である.
これを “ $\bar{X}_n$ は $n \rightarrow \infty$ のとき μ に **概収束** する” という.

実習

数値実験の設計

- 方針

真の平均と標本平均を比較する.
標本平均は観測データに依存するので, 統計的な性質を見るには繰り返し実験 (Monte-Carlo 法) を行う.

- 適当な分布を設定する (例: 偏りのあるサイコロ)
- n 個の確率変数 (乱数) の標本平均を計算する
- 真の平均と標本平均の差を計算する
- n を大きくしたときの差の性質を観察する

中心極限定理

中心極限定理の概要

- 大数の法則の主張
 - n を大きくすると標本平均 $\bar{X}_n$ は真の平均 μ に近づく

- 推定誤差 $\bar{X}_n - \mu$ は n を大きくすると 0 に近づく
- どの程度の大きさになるのか定量的な評価は与えていない
- 誤差の評価の定量化とは
 - 推定誤差がある区間 $[\alpha, \beta]$ に入る確率で定量的に評価可能

$$P(\alpha \leq \bar{X}_n - \mu \leq \beta)$$

- 上式の正確な計算は一般には困難
- サンプル数が多い場合の定量的な評価の近似方法を述べたのが **中心極限定理**

中心極限定理

- 定理

$X_1, X_2, \dots$ を独立同分布な確率変数列とし、その平均を μ 、標準偏差を σ とする。このとき、すべての実数 $a < b$ に対して

$$P\left(a \leq \frac{\sqrt{n}(\bar{X}_n - \mu)}{\sigma} \leq b\right) \rightarrow \frac{1}{\sqrt{2\pi}} \int_a^b e^{-\frac{x^2}{2}} dx \quad (n \rightarrow \infty)$$

が成り立つ。

中心極限定理の意味

- 誤差の評価

X_i の分布が何であって、サンプル数 n が十分大きければ、標本平均と真の平均の差 $\bar{X}_n - \mu$ の分布は**標準正規分布**で近似できる

$$P\left(a \frac{\sigma}{\sqrt{n}} \leq \bar{X}_n - \mu \leq b \frac{\sigma}{\sqrt{n}}\right) \simeq \frac{1}{\sqrt{2\pi}} \int_a^b e^{-\frac{x^2}{2}} dx$$

- 被積分関数 $\phi(x) = e^{-x^2/2}/\sqrt{2\pi}$ を**標準正規密度**という

実習

数値実験の設計

- 方針

規格化した標本平均と真の平均の差

$$Z = \frac{\sqrt{n}(\bar{X}_n - \mu)}{\sigma}$$

の分布と標準正規分布を比較する。

- 中心極限定理が正しければ、十分小さいビン $[a, b]$ におけるヒストグラムの高さ (密度) は $\phi(a)$ で近似される
- Z を多数観測し分布 (ヒストグラム) を求める
- Z の分布と標準正規密度 $\phi(x)$ を比較する
 - * 密度表示は `geom_histogram(aes(y = after_stat(density)))` を指定
 - * 標準正規密度 $\phi(x)$ は関数 `dnorm()` で計算可

少数の法則

少数の法則の概要

- ・ 滅多に起きない事が起こる回数に関する法則
- ・ 例：不良品発生率の低い工場での不良品の個数の分布

ある製品の不良品率 p はとても小さいとする。
一日に n 個 (非常に多数とする) 生産するとき、不良品は平均的には $\lambda = np$ 個発生するが、日によって不良品の個数 S_n には多少のばらつきが生じる。
個数 S_n は確率変数であり、強度 λ の **Poisson 分布** で近似できる。

- ・ この状況を正確に述べたのが **少数の法則**

少数の法則

- ・ 定理の問題設定

$X_1, X_2, \dots, X_n$ を独立な確率変数列とし、各 $i = 1, 2, \dots, n$ について X_i は確率 $p_{n,i}$ で 1 を、確率 $1 - p_{n,i}$ で 0 をとるとする

$$\begin{aligned} P(X_i = 1) &= p_{n,i}, \\ P(X_i = 0) &= 1 - p_{n,i} \quad (i = 1, 2, \dots, n). \end{aligned}$$

- ・ 定理

このときある正の実数 λ が存在して、 $n \rightarrow \infty$ のとき

$$\max_{i=1,2,\dots,n} p_{n,i} \rightarrow 0, \quad \sum_{i=1}^n p_{n,i} \rightarrow \lambda$$

ならば、任意の整数 $k \geq 0$ に対して以下が成り立つ:

$$P\left(\sum_{i=1}^n X_i = k\right) \rightarrow e^{-\lambda} \frac{\lambda^k}{k!} \quad (n \rightarrow \infty).$$

- 定理の $\sum_{i=1}^n X_i$ が不良品の例の S_n に対応

Poisson 分布

- ・ 定義

確率変数 X の取りうる値が 0 以上の整数全体で、値が整数 $k \geq 0$ となる確率が

$$P(X = k) = e^{-\lambda} \frac{\lambda^k}{k!}$$

で与えられるものを強度 λ の **Poisson 型確率変数** その確率法則を強度 λ の **Poisson 分布** と呼ぶ。

実習

数値実験の設計

- ・ 方針

小さな確率で $X = 1$ となる確率変数を多数観測し、その合計値の分布を調べ、Poisson 分布と比較する。

- 確率 $P(X = 1) = p$ を小さな値に設定する
- n 個 (非常に多数) の確率変数の合計 S_n を計算する
- S_n を多数観測し分布を求める
- S_n の分布を強度 $\lambda = pn$ の Poisson 分布と比較する
 - * 確率 p サイズ n の二項乱数 `rbinom()` が利用可能
 - * Poisson 分布の確率値は関数 `dpois()` で計算可能

補遺

重複対数の法則

- 定理

$X_1, X_2, \dots$ を独立同分布な確率変数列とし、その平均を μ 、標準偏差を σ とする。このとき

$$\limsup_{n \rightarrow \infty} \frac{\sqrt{n}(\bar{X}_n - \mu)}{\sqrt{2\sigma^2 \log \log n}} = 1 \quad \text{a.s.},$$
$$\liminf_{n \rightarrow \infty} \frac{\sqrt{n}(\bar{X}_n - \mu)}{\sqrt{2\sigma^2 \log \log n}} = -1 \quad \text{a.s.}$$

が成り立つ。

- 大数の法則と中心極限定理の中間的な評価と考えることができる

Hartman-Wintner の定理

- 定理

前定理の条件のもと、列

$$\left\{ \frac{\sqrt{n}(\bar{X}_n - \mu)}{\sqrt{2\sigma^2 \log \log n}} \right\}_{n=3}^{\infty}$$

のある部分列の収束先となるような実数全体の集合を C とすると、 C が閉区間 $[-1, 1]$ に一致する確率は 1 である。

次回の予定

- 一般の確率変数
- 離散分布
 - 離散一様分布・二項分布
 - Poisson 分布・幾何分布
- 連続分布
 - 一様分布・正規分布
 - ガンマ分布・ t 分布・ F 分布