

分散分析

第12講 - 複数のグループ間の違いを検証する

村田 昇

講義概要

- 分散分析とは
- 一元配置
 - 一元配置のモデル
 - 検定の構成
- 二元配置
 - 二元配置のモデル
 - 検定の構成

分散分析とは

分散分析

- 平均の差の検定
2つのグループ間で平均の差があるか否か
- 分散分析
2つ以上のグループ間で平均の差があるか否か
- 分散分析における仮説の例
 - ある小売店について“売上高は月によって差があるか”
 - ある銘柄の株価について“収益率は曜日によって差があるか”

基本的な考え方

- データの変動 (分散) = 不確定性 を分解
 - グループ間での変動
 - 観測誤差のみに起因する変動
- 変動の大きさを比較
 - 平均に差がない：自由度を除いて両者に本質的な差がない
 - 平均に差がある：グループ間の変動が増してより大きくなる
- 分散分析は“データの変動の分析”

分散の比の検定 (再掲)

分散の比の検定

- 2 種類のデータの分散が等しいか否かを検定する

$$H_0: \sigma_1^2 = \sigma_2^2 \quad \text{vs} \quad H_1: \sigma_1^2 \neq \sigma_2^2$$

考え方

- $X_1, \dots, X_m$ および $Y_1, \dots, Y_n$ の不偏分散: s_1^2, s_2^2
 - このとき s_1^2, s_2^2 は独立でそれぞれ
 - $(m-1)s_1^2/\sigma_1^2$ は自由度 $m-1$ の χ^2 分布に従う
 - $(n-1)s_2^2/\sigma_2^2$ は自由度 $n-1$ の χ^2 分布に従う
- F 検定

$$\text{検定統計量: } F = \frac{s_1^2}{s_2^2} \left(= \frac{((m-1)s_1^2/\sigma_1^2)/(m-1)}{((n-1)s_2^2/\sigma_2^2)/(n-1)} \right)$$

- 帰無分布は自由度 $m-1, n-1$ の F 分布

両側検定の棄却域

- 有意水準を選択: $\alpha \in (0, 1)$
- H_0 の下では以下が成立

$$P(F < F_{\alpha/2}(m-1, n-1) \text{ または } F > F_{1-\alpha/2}(m-1, n-1)) = \alpha$$

- 自由度 $m-1, n-1$ の F 分布
 - $F_{\alpha/2}(m-1, n-1)$: $\alpha/2$ 分位点
 - $F_{1-\alpha/2}(m-1, n-1)$: $1-\alpha/2$ 分位点
- 第一種過誤の上限が α の棄却域

$$R_\alpha = (0, F_{\alpha/2}(m-1, n-1)) \cup (F_{1-\alpha/2}(m-1, n-1), \infty)$$

- データから検定統計量 F の値を計算
- 以下の場合, 帰無仮説を棄却

$$F < F_{\alpha/2}(m-1, n-1) \quad \text{または} \quad F > F_{1-\alpha/2}(m-1, n-1)$$

一元配置

一元配置の問題設定

- グループ分けが 1 種類: p グループ $A_1, A_2, \dots, A_p$
- 各グループ i ごとに n_i 個のデータを観測

$$Y_{i1}, Y_{i2}, \dots, Y_{in_i}, \quad (i = 1, 2, \dots, p)$$

- 小売店の売上高の問題

- $A_1, A_2, \dots, A_p$: 月
- $Y_{i1}, Y_{i2}, \dots, Y_{in_i}$: i 月の各日における売上高

一元配置のモデル

- 分散分析の用語
 - 因子 : グループ分けのこと (月ごと)
 - 水準 : 因子内の各グループのこと (1 月, 2 月, 3 月, ...)
- 観測データのモデル

$$Y_{ij} = \mu_i + \varepsilon_{ij} \quad (i = 1, \dots, p; j = 1, \dots, n_i).$$

- モデルの仮定
 - 水準 A_i における観測データの平均値 μ_i は定数
 - ε_{ij} は独立同分布 (平均 0, 分散 σ^2 の正規分布)

一元配置の検定

- 検定問題

各水準 $A_1, A_2, \dots, A_p$ の平均 $\mu_1, \mu_2, \dots, \mu_p$ に差があるか否かを検定する

- 帰無仮説 : 全ての水準で平均に差はない
- 対立仮説 : 平均の異なる水準がある

$$H_0 : \mu_1 = \dots = \mu_p \quad \text{vs} \quad H_1 : \text{ある } i, j \text{ に対して } \mu_i \neq \mu_j.$$

分析の考え方

- データの変動から因子間での変動と観測誤差の変動を抽出して比較
- 各種平均 ($n = \sum_{i=1}^p n_i$ は全サンプル数)

$$\text{(全データの標本平均)} \quad \bar{Y}_{..} = \frac{1}{n} \sum_{i=1}^p \sum_{j=1}^{n_i} Y_{ij},$$

$$\text{(水準 } A_i \text{ の標本平均)} \quad \bar{Y}_{i.} = \frac{1}{n_i} \sum_{j=1}^{n_i} Y_{ij} \quad (i = 1, \dots, p).$$

- 各種変動

$$\text{(全変動)} \quad SS_T = \sum_{i=1}^p \sum_{j=1}^{n_i} (Y_{ij} - \bar{Y}_{..})^2,$$

$$\text{(級内変動)} \quad SS_W = \sum_{i=1}^p \sum_{j=1}^{n_i} (Y_{ij} - \bar{Y}_{i.})^2,$$

$$\text{(級間変動)} \quad SS_B = \sum_{i=1}^p \sum_{j=1}^{n_i} (\bar{Y}_{i.} - \bar{Y}_{..})^2 = \sum_{i=1}^p n_i (\bar{Y}_{i.} - \bar{Y}_{..})^2.$$

- **級内変動** : 各水準内でのデータの変動の合計 (観測誤差に起因)
- **級間変動** : 水準間でのデータの変動の合計 (水準ごとのデータ数で重みづけ)

- 変動の分解

$$\underbrace{\text{(全変動)} SS_T}_{\text{自由度 } n-1} = \underbrace{\text{(級内変動)} SS_W}_{\text{自由度 } n-p} + \underbrace{\text{(級間変動)} SS_B}_{\text{自由度 } p-1}$$

- 帰無仮説 H_0 が正しい場合
 - 水準内・水準間でのデータの変動はともに観測誤差が原因
 - 自由度を除けば本質的な違いはない
 - $SS_T/(n-1)$ は σ^2 の不偏推定量
 - $SS_W/(n-p)$, $SS_B/(p-1)$ もともに σ^2 の不偏推定量

- 変動の分解

$$\underbrace{\text{(全変動)} SS_T}_{\text{自由度 } n-1} = \underbrace{\text{(級内変動)} SS_W}_{\text{自由度 } n-p} + \underbrace{\text{(級間変動)} SS_B}_{\text{自由度 } p-1}$$

- 対立仮説 H_1 が正しい場合
 - 水準間での変動 SS_B は観測誤差と平均値の差に影響される
 - SS_B は SS_W より本質的に大きくなる

一元配置の検定

- 検定統計量

$$F = \frac{SS_B/(p-1)}{SS_W/(n-p)}$$

- 帰無仮説の下で次の事実が成り立つ
 - SS_B, SS_W は独立
 - SS_B/σ^2 は自由度 $p-1$ の χ^2 分布に従う
 - SS_W/σ^2 は自由度 $n-p$ の χ^2 分布に従う
- 帰無分布は自由度 $p-1, n-p$ の F 分布に従う
- 対立仮説の下 F は大きな値をとるので右片側検定

棄却域を用いる場合

- 有意水準を選択: $\alpha \in (0, 1)$
- 自由度 $p-1, n-p$ の F 分布
 - $F_{1-\alpha}(p-1, n-p)$: $1-\alpha$ 分位点
- H_0 の下で以下が成立

$$P(F > F_{1-\alpha}(p-1, n-p)) = \alpha$$

- 第一種過誤の上限が α となる棄却域

$$R_\alpha = (F_{1-\alpha}(p-1, n-p), \infty)$$

- データから検定統計量 F の値を計算
- 以下の場合, 帰無仮説を棄却

$$F > F_{1-\alpha}(p-1, n-p)$$

p 値を用いる場合

- p 値を計算 (右片側検定の場合の計算方法)

$$(p \text{ 値}) = \int_F^\infty f(x) dx$$

- $f(x)$ は自由度 $p-1, n-p$ の F 分布の確率密度
- p 値が α 未満なら帰無仮説を棄却

分散分析表 (一元配置の場合)

	自由度	平方和	平均平方和	F 値	p 値
級間	$p-1$	SS_B	$SS_B/(p-1)$	F	$\int_F^\infty f(x) dx$
級内	$n-p$	SS_W	$SS_W/(n-p)$		
全変動	$n-1$	SS_T			

- $f(x)$ は自由度 $p-1, n-p$ の F 分布の確率密度

モデルの別表現

- 各水準の平均値の相対効果による定式化
 - 因子 A 全体の平均効果: μ
 - 平均 μ を基準とした各水準 A_i の相対的な効果: α_i
 - 平均値の別表現

$$\mu_i = \mu + \alpha_i, \quad \mu = \frac{1}{n} \sum_{i=1}^p n_i \mu_i, \quad \sum_{i=1}^p n_i \alpha_i = 0$$

- 帰無仮説 H_0 は以下と同等

$$H_0: \alpha_1 = \cdots = \alpha_p = 0$$

分散分析の計算

- 基本書式

```
aov(formula, data)
#' formula: 式, 一元配置の場合は (観測値 ~ 因子)
#' data: データフレーム
#' 分析の結果を参照する関数があるので, 多くの場合適当なオブジェクトに代入
```

- 分散分析表の表示

```
aov(formula, data) |> summary()      # 分析表形式での表示
aov(formula, data) |> anova()        # データフレーム (data.frame形式)
aov(formula, data) |> broom::tidy()  # データフレーム (tibble形式)
aov(formula, data) |> model.tables(type = "means")  # 平均値
aov(formula, data) |> model.tables(type = "effects") # 効果 (既定値)
```

分散分析の計算 (検定のみ)

- 基本書式

```
oneway.test(formula, data, subset, na.action, var.equal = FALSE)
#' formula: 式
#' data: データフレーム
#' subset: subsetの指定
#' na.action: 欠損値の扱い
#' var.equal: 等分散を仮定する場合は TRUE, 標準では Welch の近似が用いられる
```

実習

二元配置

二元配置の問題

- 因子が2種類ある場合
 - 一方の因子の水準の平均値に差があるか否かを検定
 - もう一方の因子の水準で平均値に差があるかは不問
- 複数の薬の治験の問題

複数の薬を複数の被験者に投与する実験

- “薬の種類” と “被験者番号” の2種類の因子
- “薬の種類” という因子での薬の効能の差を検証したい
- “被験者番号” という因子で効能に差があることは許容したい (薬の効き目には個人差があると考えられるため)

二元配置のモデル

- 2種類の因子 A, B
 - 因子 A には a 個の水準: $A_1, \dots, A_a$
 - 因子 B には b 個の水準: $B_1, \dots, B_b$
 - 因子 A, B の水準がそれぞれ A_i, B_j である観測値: Y_{ij}
 - 各水準ごとに1つの観測値が得られる一番簡単な場合を想定
- 観測データのモデル

$$Y_{ij} = \alpha_i + \beta_j + \varepsilon_{ij} \quad (i = 1, \dots, a; j = 1, \dots, b).$$

- モデルの仮定
 - 因子 A, B の水準 A_i, B_j における効果 α_i, β_j は定数
 - ε_{ij} は独立同分布 (平均 0, 分散 σ^2 の正規分布)

二元配置の例

- 複数の薬の治験の問題
 - 因子
 - * 因子 A : “薬の種類”
 - * 因子 B : “被験者番号”
 - 効果
 - * α_i : 薬 A_i の効能
 - * β_j : 被験者 B_j 固有の薬の効きやすさ
 - 薬の効能に差があるか否かという検定

二元配置の検定

- 検定問題
 - 因子 A の各水準の効能に差があるか否かを検定する
(因子 B の効果は除いて検定したい)
 - 帰無仮説: 因子 A の効果 α_i に差はない
 - 対立仮説: 因子 A の効果に差のあるものがある

$$H_0: \alpha_1 = \dots = \alpha_a \quad \text{vs} \quad H_1: \text{ある } i_1, i_2 \text{ に対して } \alpha_{i_1} \neq \alpha_{i_2}.$$

分析の考え方

- データの変動から因子間での変動と観測誤差の変動を抽出して比較
- 各種平均 ($n = ab$)

$$\text{(全データの標本平均)} \quad \bar{Y}_{..} = \frac{1}{n} \sum_{i=1}^a \sum_{j=1}^b Y_{ij},$$

$$\text{(水準 } A_i \text{ の標本平均)} \quad \bar{Y}_{i.} = \frac{1}{b} \sum_{j=1}^b Y_{ij} \quad (i = 1, \dots, a),$$

$$\text{(水準 } B_j \text{ の標本平均)} \quad \bar{Y}_{.j} = \frac{1}{a} \sum_{i=1}^a Y_{ij} \quad (j = 1, \dots, b).$$

- 因子効果の推定量としての標本平均

$$\bar{Y}_{i.} \rightarrow \alpha_i + \frac{1}{b} \sum_{j=1}^b \beta_j,$$

$$\bar{Y}_{.j} \rightarrow \frac{1}{a} \sum_{i=1}^a \alpha_i + \beta_j,$$

$$\bar{Y}_{..} \rightarrow \frac{1}{ab} \sum_{i=1}^a \sum_{j=1}^b (\alpha_i + \beta_j) = \frac{1}{a} \sum_{i=1}^a \alpha_i + \frac{1}{b} \sum_{j=1}^b \beta_j$$

$$Y_{ij} - \bar{Y}_{i.} - \bar{Y}_{.j} + \bar{Y}_{..} \rightarrow \varepsilon_{ij}$$

- 各種変動

$$\text{(行間変動)} \quad SS_A = b \sum_{i=1}^a (\bar{Y}_{i.} - \bar{Y}_{..})^2,$$

$$\text{(列間変動)} \quad SS_B = a \sum_{j=1}^b (\bar{Y}_{.j} - \bar{Y}_{..})^2,$$

$$\text{(誤差変動)} \quad SS_E = \sum_{i=1}^a \sum_{j=1}^b (Y_{ij} - \bar{Y}_{i.} - \bar{Y}_{.j} + \bar{Y}_{..})^2.$$

- 行間変動: 水準 A 内でのデータの変動
- 列間変動: 水準 B 内でのデータの変動

- 変動の分解

$$\underbrace{\text{(全変動)} SS_T}_{\text{自由度 } ab-1} = \underbrace{\text{(行間変動)} SS_A}_{\text{自由度 } a-1} + \underbrace{\text{(列間変動)} SS_B}_{\text{自由度 } b-1} + \underbrace{\text{(誤差変動)} SS_E}_{\text{自由度 } (a-1)(b-1)}$$

- 帰無仮説 H_0 が正しい場合
 - 変動 SS_A, SS_E はともに観測誤差のみが原因で生じる
 - 自由度を除けば本質的な違いはない
 - $SS_A/(a-1), SS_E/(a-1)(b-1)$ は σ^2 の不偏推定量
- 変動の分解

$$\underbrace{\text{(全変動)} SS_T}_{\text{自由度 } ab-1} = \underbrace{\text{(行間変動)} SS_A}_{\text{自由度 } a-1} + \underbrace{\text{(列間変動)} SS_B}_{\text{自由度 } b-1} + \underbrace{\text{(誤差変動)} SS_E}_{\text{自由度 } (a-1)(b-1)}$$

- 対立仮説 H_1 が正しい場合
 - 因子 A 内の水準間での効果 $\alpha_1, \dots, \alpha_a$ の差に影響される
 - SS_A は SS_E より本質的に大きくなる

二元配置の検定

- 検定統計量

$$F_A = \frac{SS_A/(a-1)}{SS_E/(a-1)(b-1)}$$

- 帰無仮説の下で次の事実が成り立つ
 - SS_A, SS_E は独立
 - SS_A/σ^2 は自由度 $a-1$ の χ^2 分布に従う
 - SS_E/σ^2 は自由度 $(a-1)(b-1)$ の χ^2 分布に従う
- 帰無仮説の下 F_A は自由度 $a-1, (a-1)(b-1)$ の F 分布に従う
- 対立仮説の下 F_A は大きな値をとるので右片側検定

棄却域を用いる場合

- 有意水準: $\alpha \in (0, 1)$
- 自由度 $a-1, (a-1)(b-1)$ の F 分布
 - $F_{1-\alpha}(a-1, (a-1)(b-1))$: $1-\alpha$ 分位点
- H_0 の下で以下が成立

$$P(F_A > F_{1-\alpha}(a-1, (a-1)(b-1))) = \alpha$$

- 第一種過誤の上限が α となる棄却域

$$R_\alpha = (F_{1-\alpha}(a-1, (a-1)(b-1)), \infty)$$

- データから検定統計量 F_A の値を計算
- 以下の場合, 帰無仮説を棄却

$$F_A > F_{1-\alpha}(a-1, (a-1)(b-1))$$

p 値を用いる場合

- p 値を計算 (右片側検定の場合の計算方法)

$$(p \text{ 値}) = \int_{F_A}^{\infty} f(x) dx$$

- f は自由度 $a-1, (a-1)(b-1)$ の F 分布の確率密度
- p 値が α 未満なら帰無仮説を棄却

分散分析表 (二元配置の場合)

	自由度	平方和	平均平方和	F 値	p 値
因子 A	$a-1$	SS_A	$\frac{SS_A}{a-1}$	F_A	$\int_{F_A}^{\infty} f(x) dx$
因子 B	$b-1$	SS_B	$\frac{SS_B}{b-1}$	F_B	$\int_{F_B}^{\infty} g(x) dx$
誤差	$(a-1)(b-1)$	SS_E	$\frac{SS_E}{(a-1)(b-1)}$		

- f は自由度 $a-1, (a-1)(b-1)$ の F 分布の確率密度
- g は自由度 $b-1, (a-1)(b-1)$ の F 分布の確率密度

モデルの別表現

相対効果による定式化

- モデルの書き換え

$$\mu^* = \bar{\alpha} + \bar{\beta},$$

$$\alpha_i^* = \alpha_i - \bar{\alpha},$$

$$\beta_j^* = \beta_j - \bar{\beta}$$

$$\bar{\alpha} = \frac{1}{a} \sum_{i=1}^a \alpha_i,$$

$$\bar{\beta} = \frac{1}{b} \sum_{j=1}^b \beta_j$$

$$Y_{ij} = \mu^* + \alpha_i^* + \beta_j^* + \varepsilon_{ij} \quad (i = 1, \dots, a; j = 1, \dots, b)$$

$$\text{ただし } \sum_{i=1}^a \alpha_i^* = \sum_{j=1}^b \beta_j^* = 0$$

- 帰無仮説 H_0 は以下と同等

$$H_0 : \alpha_1^* = \dots = \alpha_a^* = 0$$

分散分析の計算

- 基本書式

```
aov(formula, data)
#' formula: 式, 二元配置の場合は (観測値 ~ 因子 + 因子)
#' data: データフレーム
```

- 分散分析表なども同様

実習

次回の予定

- 回帰分析
- 回帰係数の推定
 - 点推定
 - 区間推定
- 回帰係数の検定
 - 係数の有意性
- 決定係数